

# Raghuram Kalyanam

## Senior AI Engineer



🇩🇪 Deutscher Staatsbürger 📍 Neudorfstr.10, 6313 Menzingen, CH 📞 +(41) 797515004  
✉️ [raghuramkalyanam@gmail.com](mailto:raghuramkalyanam@gmail.com) 🔗 [linkedin.com/in/raghuramkalyanam](https://www.linkedin.com/in/raghuramkalyanam) 🐙 [github.com/raghu1121](https://github.com/raghu1121)

Erfahrener Data Scientist mit 13 Jahren Berufserfahrung, davon 10 Jahre im Bereich maschinelles Lernen und KI, spezialisiert auf LLM-gestützte Systeme, RAG-Pipelines, GenAI, semantische Suche, Fraud Detection und Optimierungsmodelle. Nachweisliche Erfahrung in der Umsetzung komplexer Projekte in den Bereichen Finanzen, Automobil, Leasing, Luftfahrt und Bauwesen. Fundierte Kenntnisse in Cloud-Architektur, ML-Frameworks, Reinforcement Learning, Hyperparameteroptimierung und MLOps.

## 📁 Berufserfahrung

Oktober 2025  
Heute

### Senior Data Scientist / Consultant, ELCA Informatique SA, Zürich

- Maßgeblich an Architektur und Lösungsdesign zweier KI-Plattformen (GenKI St. Gallen & Serafe) beteiligt – Schwerpunkt auf RAG-Systemen, Modellauswahl, Datenindexierung und skalierbarem Infrastrukturaufbau.
- Recherche, Experimente und Benchmarking verschiedener Open-Source-LLMs und Embedding-Modelle zur Identifikation optimaler Konfigurationen für unternehmensweite Anwendungsfälle.
- Aufbau und Konfiguration skalierbarer Container-Infrastrukturen (Docker Swarm) sowie Integration von Open WebUI, LiteLLM, Bifrost und Ollama für modularen und produktionsreifen Modellbetrieb.
- Erstellung eines Golden Datasets und Evaluierungs-Frameworks zur systematischen Messung von Retrievalqualität, Modellgenauigkeit und End-to-End-Pipeline-Performance.
- Entwicklung und Optimierung von Datenindexierungs- und Retrievalstrategien, einschließlich multi-modaler Ansätze zur Oberflächung relevanter Bildinhalte aus komplexen Dokumentensammlungen.
- Analyse und Behebung von Inferenz-Engpässen sowie Entwicklung alternativer Lösungsansätze zur Steigerung von Antwortqualität und Systemstabilität.
- Integration von Keycloak für Authentifizierung und Zugriffskontrolle sowie Aufbau von Observability-Pipelines mit Grafana und Prometheus für überwachten Produktionsbetrieb.
- Automatisierung von Deployment-Pipelines mittels GitLab CI/CD und Python zur Vereinfachung von Modell-Updates und Konfigurationsmanagement.
- Beratung und enge Zusammenarbeit mit Stakeholdern beider Projekte – verständliche Kommunikation von Methodik, Trade-offs und technischen Lösungen gegenüber technischen und nicht-technischen Zielgruppen.

Open WebUI | LiteLLM | Bifrost | Keycloak | Grafana | Prometheus | Ollama | Docker Swarm | GitLab CI/CD | Python  
RAG Pipelines | LLMs | Embedding Models | Evaluation Frameworks | Vector Search | Multimodal Retrieval

Juli 2022  
September 2025

### Senior Data Scientist, Mercedes-Benz Mobility AG, Stuttgart

- Entwicklung eines LLM-gestützten semantischen Abfragesystems, das Inkasso-Mitarbeitern ermöglicht, Hochrisikokunden über natürliche Sprachabfragen zu identifizieren.
- Einsatz von Model Context Protocols (MCPs) zur Übersetzung von Nutzerintentionen in gewichtete SQL-/Vektorabfragen und Weiterleitung an relevante Datenquellen (Risikohistorie, Zahlungsprofile, Verhaltensdaten).
- Das LLM fungiert als Intent-Parser und semantischer Anreicherer – interpretiert Geschäftssprache, erstellt kontextuelle Embeddings und optimiert die Abfragepräzision.
- Integration von Whisper zur Transkription von Kundengesprächen und semantischen Indexierung, um Gesprächsdaten nach Tonfall, Intention und Risiko durchsuchbar zu machen.
- Aufbau eines semantischen Fraud-Reasoning-Systems (Credit Risk Assist) mit Superlinked für hybride Suche – Kombination von Vektorembodings aus Analystenkommentaren mit strukturierten Finanzkennzahlen.
- Einsatz von FAISS für eigenständige Embedding-Ähnlichkeitsanalysen zur Clusterung historischer Betrugsmuster und Identifikation anomaler Empfehlungstrends.
- Nutzung von LangGraph zur Orchestrierung mehrstufiger Fraud-Reasoning-Workflows (Retrieval, Scoring, Erklärungen) für transparente und nachvollziehbare Risikobewertungen.
- Integration von OpenAI Function Calling zur dynamischen Ausführung interner Fraud-Scoring-Funktionen und Abruf strukturierter Finanzdaten während der LLM-Analyse.

LLMs | LangChain | LangGraph | MCPs | Vektordatenbanken (ChromaDB) | pgvector | FAISS | Superlinked | Whisper  
Ollama | LiteLLM | GPT-4-turbo | Mistral | Hugging Face Transformers | FastAPI | Docker | MLOps | PySpark | SQL

Januar 2020  
Mai 2022

#### Data Scientist / Consultant, Lufthansa Industry Solutions GmbH, Raunheim

- › Entwicklung einer KI-Plattform zur Zeitreihenvorhersage mit Rolling-Prediction-Mechanismen und automatisierten Retraining-Pipelines für domänenspezifische Prognosemodelle.
- › Aufbau robuster ETL-Workflows zur Extraktion, Bereinigung und Anreicherung von Daten mit externen Regressoren; bayessche Hyperparameteroptimierung zur kontinuierlichen Leistungsverbesserung.
- › Modellierung von Ressourcen- und Scheduling-Problemen als Reinforcement-Learning-Aufgaben, gelöst mit DQN-Varianten für optimierte Entscheidungsfindung.
- › Containerisierung von Trainings- und Inferenzdiensten mit Docker und Kubernetes zur Sicherstellung skalierbarer Bereitstellung und Überwachung in der Produktion.
- › Zusammenarbeit mit Kunden aus der Luftfahrt-, Automobil- und öffentlichen Branche; Mentoring von Junior-Data-Scientists und Beratung zu ML-Architekturen.

FastAPI PyTorch TensorFlow MLflow scikit-learn Prophet skforecast Docker Kubernetes Azure Terraform  
Microservices MLOps PySpark SQL

Mai 2015  
Oktober 2019

#### Wissenschaftlicher Mitarbeiter, TU Kaiserslautern | LivingLab SmartOfficeSpace, Kaiserslautern

- › Entwicklung von Reinforcement-Learning-Modellen zur Steuerung adaptiver Glashtransparenz zur Optimierung von visuellen und thermischen Komfortbedingungen in Smart-Office-Umgebungen.
- › Aufbau einer Tageslichtsimulationsumgebung zur Generierung synthetischer Daten für RL- und Prognosemodelle sowie großskalige Hyperparameteroptimierung mit Ray Tune.
- › Gestaltung von ETL- und Datenverarbeitungspipelines zur Integration visueller, thermischer und Belegungsdaten aus dem LivingLab.
- › Zusammenarbeit mit dem SBRC (University of Wollongong, Australien) zur Entwicklung eines Co-Simulationsframeworks für Gebäudeleistung und Nutzerkomfort.
- › Einsatz und kontinuierliche Verbesserung von RL- und Deep-Learning-Modellen basierend auf Nutzerfeedback und Umgebungsvalidierung.

RLlib Ray Tune PyTorch TensorFlow OpenAI Gym Keras Flask Tree-based Models Spark Hadoop SQLite

November 2012  
Februar 2015

#### Software Engineer, Ericsson R&D Center, Chennai, Indien

- › Teil des agilen Teams zur Entwicklung von Datenabrechnungsanwendungen für Prepaid- und Postpaid-Kunden; Implementierung von VoLTE (Java) und Diameter (C++) Protokollen für Telekommunikationsabrechnungssysteme.
- › Knotenverbesserungen und Behebung von Fehlermeldungen zur Verkürzung der Bearbeitungszeiten; Rufbereitschaft für internationale Kunden.
- › Produktdokumentation, Release-Management und Verpackung von Software-Releases.

Java C++ Design Patterns Eclipse Postgres Wireshark Jenkins Jira Git

## Ausbildung

2007-2012 M.Sc Mathematik und Informatik, IIT Dhanbad, Indien.

## IT-Kenntnisse

|                       |                                                                                       |
|-----------------------|---------------------------------------------------------------------------------------|
| Programmiersprachen   | Python, SQL, Java, TypeScript, Node.js.                                               |
| Machine Learning & AI | scikit-learn, PyTorch, TensorFlow, XGBoost, Reinforcement Learning, NLP, LLMs, RAG.   |
| GenAI & LLMOps        | LangChain, LangGraph, OpenAI API, Mistral, LLaMA, FAISS, Superlinked, Copilot Studio. |
| Cloud & DevOps        | Azure, AWS, SageMaker, Kubernetes, Docker, Helm, Terraform, Databricks, AKS, CI/CD.   |
| Webentwicklung        | React, Node.js, TypeScript, FastAPI, Flask.                                           |
| Tools & Plattformen   | MLflow, Git, Power BI, Grafana, Postgres, Airflow, Streamlit.                         |

## Sprachen

|          |                     |
|----------|---------------------|
| Englisch | fließend            |
| Deutsch  | fließend, C1 Niveau |

## Publikationen

- › Kalyanam, Raghuram, and Sabine Hoffmann. 2021. "A Reinforcement Learning- Based Approach to Automate the Electrochromic Glass and to Enhance the Visual Comfort" *Applied Sciences* 11, no. 15 : 6949.
- › Kalyanam, Raghuram, and Sabine Hoffmann. "Reinforcement learning based approach to automate the external shading system and enhance the occupant comfort." *AI in AEC conference*, Helsinki, Finland, March 2021.
- › Kalyanam, Raghuram, and Sabine Hoffmann. "A Novel Approach to Enhance the Generalization Capability of the Hourly Solar

- Diffuse Horizontal Irradiance Models on Diverse Climates.” *Energies* 13.18 (2020) : 4868.
- Kalyanam, Raghuram and Sabine Hoffmann. 2016. “Visual and thermal comfort with electrochromic glass using an adaptive control strategy.” Paper presented at the *15th International Radiance Workshop (IRW)*, Padua, Italy, August 2016.
  - Boudier, Katharina, Massimo Fiorentini, Sabine Hoffmann, Raghuram Kalyanam, and Georgios Kokogiannakis. 2016. “Coupling a thermal comfort model with building simulation for user comfort and energy efficiency.” *In Proceedings of the Central European Symposium on Building Physics (CESBP) and BauSIM*, Dresden, Germany, September 2016, 481–487.
  - Hoffmann, Sabine, Andrew McNeil, Eleanor S. Lee, and Raghuram Kalyanam. 2015. “Discomfort glare with complex fenestration systems and the impact on energy use when using daylighting control.” *In Proceedings of the Advanced Building Skins Conference*, Bern, Switzerland, November 2015.