

Raghuram Kalyanam

Senior AI Engineer



i Deutscher Staatsbürger **📍** Neudorfstr.10, 6313 Menzingen, CH **☎** +(41) 797515004
@ raghuramkalyanam@gmail.com **in** linkedin.com/in/raghuramkalyanam
🌐 raghuramkalyanam.github.io

Senior Data Scientist / AI Engineer mit 14 Jahren Berufserfahrung, davon 11 Jahre in maschinellem Lernen und künstlicher Intelligenz (KI). Schwerpunkt auf produktiven Systemen mit Large Language Models (LLMs): Architektur und Retrievalqualität von Retrieval-Augmented Generation (RAG), Evaluierungsframeworks und LLM-as-Judge-Pipelines, Prompt-Architektur sowie AI-Sicherheit und Guardrails. Erfahrung darin, Generative-AI-Systeme (GenAI) vom Prototyp in den überwachten Produktivbetrieb zu bringen – in regulierten Umgebungen und im öffentlichen Sektor, einschließlich souveräner, vollständig selbst gehosteter On-Premise-Betriebsmodelle. Zuvor Zeitreihenprognose, Reinforcement Learning und MLOps in den Bereichen Finanzen, Automobil, Luftfahrt und Bauwesen.

Berufserfahrung

Okt. 2025
Heute

Senior Data Scientist / Consultant, ELCA Informatique SA, Zürich

- Entwicklung eines internen, mehrsprachigen Mitarbeitendenassistenten über einen Korpus offizieller Arbeitsanweisungen für eine führende Schweizer Inkassoagentur – Antworten auf Deutsch, Französisch und Italienisch, ausschließlich auf die Handbücher gestützt, mit Chainlit, OpenSearch, LiteLLM und Qwen3.
- Ersetzen eines Designs, bei dem das LLM den Handbuchkatalog selbst durchsuchte, durch eine dedizierte Suchmaschine – deutlich geringere Latenz und Kosten pro Frage; Korrektur der Behandlung deutscher Komposita bei der Query-Bildung, wodurch die Quellenauswahl wesentlich zuverlässiger wurde.
- Optimierung des Retrievals mit sprachspezifischen Analyzern, kompositabewusster Query-Gestaltung, LLM-generierten Abschnitts-Tags und gestuftem Score-Trimming, sodass nur antwortrelevante Passagen zum Modell gelangen und die Input-Tokens pro Anfrage sanken.
- Aufbau der Antwortstrecke als gestufte Prompts: Klassifikation und Erweiterung der Frage, eine agentische Retrieval-Schleife zur Auswahl der relevanten Abschnitte, und ein Antwortkritiker, der Sprache, Groundedness und Relevanz prüft, bevor eine Antwort erscheint.
- Entwicklung einer souveränen, vollständig selbst gehosteten GenAI-Assistenzplattform für den Kanton St. Gallen für als vertraulich und geheim klassifizierte Dokumente, mit zweckspezifischen Assistenten für Schreiben, Recherche und Zusammenfassung, mit Open WebUI, Bifrost, vLLM und Gemma.
- Entwurf der Prompt-Architektur für regelkonforme Assistenten: Verdichtung umfangreicher amtlicher Regelwerke in stabile, cachebare System-Prompts, nachdem drei Designalternativen in einem kontrollierten Vergleich gemessen wurden.
- Aufbau von Evaluierungsframeworks mit DeepEval und MLflow – deterministische Regelmetriken, LLM-Judges aus einer anderen Modellfamilie und Fehlerattribution zwischen Retrieval und Generierung, geprüft gegen das laufende System statt gegen einen vereinfachten Ersatz.
- Zuordnung der Schutzmaßnahmen aus der Datenschutz-Folgenabschätzung (DSFA) sowie der OWASP Top 10 für LLM-Anwendungen auf konkret implementierte Kontrollen; Behebung der in einem Deployment-Audit gefundenen Mängel.
- Produktivsetzung der Plattformschicht: Reindexierung ohne Ausfallzeit, Single Sign-on über Keycloak OIDC mit RBAC aus Verzeichnisgruppen, Observability mit Prometheus und Grafana samt Kostenzuordnung pro Anwendungsfall sowie GitLab CI/CD.
- Evaluierung von Cross-Encoder-Reranking und Vektorsuche mit dokumentierter Entscheidung, für einen kuratierten deutschen Korpus beim lexikalischen Retrieval zu bleiben.

LLMs RAG OpenSearch BM25 Open WebUI LiteLLM Bifrost Ollama vLLM Qwen3 Gemma DeepEval
MLflow Chainlit FastAPI Keycloak Prometheus Grafana Docker GitLab CI/CD Azure OpenAI Python
Prompt Engineering LLM-as-Judge Guardrails DSFA

Juli 2022
Sep. 2025

Senior Data Scientist, Mercedes-Benz Mobility AG, Stuttgart

- > Entwicklung eines LLM-gestützten semantischen Abfragesystems, mit dem Mitarbeitende im Forderungsmanagement Hochrisikokunden in natürlicher Sprache suchen und identifizieren konnten; die passenden Kunden wurden direkt ausgegeben.
- > Einsatz des Model Context Protocol (MCP) zur Übersetzung von Nutzerintentionen in gewichtete SQL- und Vektorabfragen über Risikohistorie, Zahlungsprofile und Verhaltensdaten – das LLM interpretiert dabei die Geschäftssprache und erhöht die Abfragepräzision, statt die Antwort selbst zu erzeugen.
- > Aufbau eines separaten semantischen Fraud-Reasoning-Systems für die Mercedes-Benz Bank zur Aufdeckung auffälliger Kreditanträge – hybride Suche über Analystenkommentare kombiniert mit strukturierten Finanzkennzahlen, Clusterung historischer Betrugsmuster mit FAISS.
- > Integration von OpenAI Function Calling zur dynamischen Ausführung interner Fraud-Scoring-Funktionen und zum Abruf strukturierter Finanzdaten während der LLM-Analyse.

LLMs LangChain MCP Vektordatenbanken (ChromaDB pgvector FAISS Superlinked) Ollama LiteLLM
Mistral Hugging Face Transformers FastAPI Docker MLOps PySpark SQL

Jan. 2020
Mai 2022

Data Scientist / Consultant, Lufthansa Industry Solutions GmbH, Raunheim

- > Entwicklung einer KI-Plattform zur Zeitreihenvorhersage mit Rolling-Prediction-Mechanismen und automatisierten Retraining-Pipelines für domänenspezifische Prognosemodelle.
- > Aufbau robuster ETL-Workflows zur Extraktion, Bereinigung und Anreicherung von Daten mit externen Regressoren; bayessche Hyperparameteroptimierung zur kontinuierlichen Leistungsverbesserung.
- > Modellierung von Ressourcen- und Scheduling-Problemen als Reinforcement-Learning-Aufgaben, gelöst mit DQN-Varianten für optimierte Entscheidungsfindung.
- > Containerisierung von Trainings- und Inferenzdiensten mit Docker und Kubernetes zur Sicherstellung skalierbarer Bereitstellung und Überwachung in der Produktion.
- > Zusammenarbeit mit Kunden aus der Luftfahrt-, Automobil- und öffentlichen Branche; Mentoring von Junior-Data-Scientists und Beratung zu ML-Architekturen.

FastAPI PyTorch TensorFlow MLflow scikit-learn Prophet skforecast Docker Kubernetes Azure Terraform
Microservices MLOps PySpark SQL

Mai 2015
Okt. 2019

Wissenschaftlicher Mitarbeiter, TU Kaiserslautern | LivingLab SmartOfficeSpace, Kaiserslautern

- > Entwicklung von Reinforcement-Learning-Modellen zur Steuerung adaptiver Glastransparenz zur Optimierung von visuellen und thermischen Komfortbedingungen in Smart-Office-Umgebungen.
- > Aufbau einer Tageslichtsimulationsumgebung zur Generierung synthetischer Daten für RL- und Prognosemodelle sowie großskalige Hyperparameteroptimierung mit Ray Tune.
- > Gestaltung von ETL- und Datenverarbeitungspipelines zur Integration visueller, thermischer und Belegungsdaten aus dem LivingLab.
- > Zusammenarbeit mit dem SBRC (University of Wollongong, Australien) zur Entwicklung eines Co-Simulationsframeworks für Gebäudeleistung und Nutzerkomfort.
- > Einsatz und kontinuierliche Verbesserung von RL- und Deep-Learning-Modellen basierend auf Nutzerfeedback und Umgebungsvalidierung.

RLlib Ray Tune PyTorch TensorFlow OpenAI Gym Keras Flask Tree-based Models Spark Hadoop SQLite

Nov. 2012
Feb. 2015

Software Engineer, Ericsson R&D Center, Chennai, Indien

- > Teil des agilen Teams zur Entwicklung von Datenabrechnungsanwendungen für Prepaid- und Postpaid-Kunden; Implementierung von VoLTE (Java) und Diameter (C++) Protokollen für Telekommunikationsabrechnungssysteme.
- > Knotenverbesserungen und Behebung von Fehlermeldungen zur Verkürzung der Bearbeitungszeiten; Rufbereitschaft für internationale Kunden.
- > Produktdokumentation, Release-Management und Verpackung von Software-Releases.

Java C++ Design Patterns Eclipse Postgres Wireshark Jenkins Jira Git

 Sprachen

Englisch	fließend
Deutsch	fließend, C1 Niveau

 IT-Kenntnisse

Programmiersprachen	Python, SQL, Java, C++.
GenAI & LLM	Generative AI (GenAI), Large Language Models (LLMs), LangChain, Model Context Protocol (MCP), Function Calling und Tool Use, OpenAI API, Azure OpenAI Service, Azure AI Foundry, LiteLLM, Bifrost, Ollama, vLLM, Open WebUI, Chainlit, Qwen3, Gemma, Mistral, LLaMA, Hugging Face Transformers.
RAG & Retrieval	Architektur für Retrieval-Augmented Generation (RAG), semantische Suche, Vektorsuche, hybride Suche, lexikalische Suche, OpenSearch, BM25 und sprachspezifische Analyzer, Query-Erweiterung und -Umschreibung, Reranking, Chunking-Strategie, multimodales Retrieval, Embedding-Modelle, Vektordatenbanken (ChromaDB, pgvector, FAISS, Superlinked), Docling.
Evaluierung & Qualität	LLM-Evaluierung, LLM-as-Judge, DeepEval, GEval, Golden Datasets, deterministische Regelmetriken, Benchmarking, Fehlerattribution im Retrieval, Regressionstests, A/B-Experimente, MLflow, Prompt-Architektur, Context Engineering, System-Prompts, Token- und Kostenoptimierung, Latenzoptimierung.
AI-Sicherheit & Governance	Guardrails, Abwehr von Prompt Injection, adversariale Testkorpora, Groundedness- und Halluzinationskontrollen, Zitationsintegrität, Responsible AI, AI Governance, OWASP Top 10 für LLM-Anwendungen, Datenschutz-Folgenabschätzung (DSFA / DPIA), DSGVO, Datenresidenz, souveräne KI, On-Premise- und selbst gehosteter LLM-Betrieb, Keycloak OIDC, Single Sign-on (SSO), RBAC.
Machine Learning	Maschinelles Lernen, Deep Learning, Natural Language Processing (NLP), Zeitreihenprognose, Anomalie- und Betrugserkennung, Reinforcement Learning, PyTorch, TensorFlow, Keras, scikit-learn, XGBoost, CatBoost, RLib, Prophet, skforecast, Ray Tune, HyperOpt, bayessche Optimierung.
Cloud & MLOps	Azure, Docker, Docker Compose, Kubernetes, Helm, Terraform, Infrastructure-as-Code, Microservices, Git-Lab CI/CD, MLOps, Observability und Model Monitoring, Prometheus, Grafana, FastAPI, Flask, Git.
Daten & Visualisierung	PySpark, Pandas, NumPy, Power BI, Matplotlib, Seaborn, Plotly, Streamlit, Postgres.
Arbeitsweise	Lösungsarchitektur, technische Beratung, Requirements Engineering, Architecture Decision Records (ADRs), Stakeholder-Management, interdisziplinäre Zusammenarbeit, Agile und Scrum, DevOps, Code Review, Mentoring, technische Dokumentation.

 Erfolge

- Rang unter den besten 1% von 400.000 Studenten, die zum IIT-JEE erschienen sind.
- Anerkennung als Rockstar bei Ericsson für meine Leistung.
- Während des gesamten Studiums erhielt ich ein Stipendium. Außerdem war ich der Beste bei mehreren Begabungstests in der Schule.

 Publikationen

- Kalyanam, Raghuram, and Sabine Hoffmann. 2021. "A Reinforcement Learning- Based Approach to Automate the Electrochromic Glass and to Enhance the Visual Comfort" *Applied Sciences* 11, no. 15: 6949.
- Kalyanam, Raghuram, and Sabine Hoffmann. "Reinforcement learningbased approach to automate the external shading system and enhance the occupant comfort." *AI in AEC conference*, Helsinki, Finland, March 2021.
- Kalyanam, Raghuram, and Sabine Hoffmann. "A Novel Approach to Enhance the Generalization Capability of the Hourly Solar Diffuse Horizontal Irradiance Models on Diverse Climates." *Energies* 13.18 (2020): 4868.
- Kalyanam, Raghuram and Sabine Hoffmann. 2016. "Visual and thermal comfort with electrochromic glass using an adaptive control strategy." Paper presented at the *15th International Radiance Workshop (IRW)*, Padua, Italy, August 2016.
- Boudier, Katharina, Massimo Fiorentini, Sabine Hoffmann, Raghuram Kalyanam, and Georgios Kokogiannakis. 2016. "Coupling a thermal comfort model with building simulation for user comfort and energy efficiency." *In Proceedings of the Central European Symposium on Building Physics (CESBP) and BauSIM*, Dresden, Germany, September 2016, 481–487.

- › Hoffmann, Sabine, Andrew McNeil, Eleanor S. Lee, and Raghuram Kalyanam. 2015. "Discomfort glare with complex fenestration systems and the impact on energy use when using daylighting control." *In Proceedings of the Advanced Building Skins Conference*, Bern, Switzerland, November 2015.